

Pre-entrega Módulo 6

Ensamblado de un circuito cerrado conversacional de voz (STT / TTS)

Versión 2 — incluye anexo con la implementación operativa

Sistema agéntico de atención al cliente — TiendaVerde S.R.L.

Ignacio Paiva	IA Automation Specialist	25 nodos	Septiembre 2026
Alumno	Coderhouse	n8n self-hosted	Informe técnico

Este checkpoint incorpora una capa de voz al sistema construido en los módulos anteriores. El cliente envía una nota de voz por Telegram, el sistema la transcribe, la procesa con el agente que ya consulta la base documental del Módulo 5, y le responde hablando.

El documento tiene dos partes. Primero el análisis de viabilidad —en qué casos la voz aporta y en cuáles agrega costo sin agregar valor—, porque decidir eso antes de construir es el trabajo del que diseña el sistema. Después el circuito, componente por componente.



1 · Análisis de viabilidad: cuándo conviene la voz

La voz no es una mejora universal de un canal de texto. Cambia la economía del proceso en dos direcciones opuestas al mismo tiempo, y conviene separarlas antes de decidir.

Dónde la voz genera retorno

Situación operativa	Por qué la voz gana
El cliente tiene las manos ocupadas	Depósito, reparto, mostrador, manejo. Dictar una consulta cuesta segundos; escribirla exige detener la tarea.

La consulta es larga de escribir y corta de decir	Describir un desperfecto lleva cuarenta segundos hablados y tres minutos escritos. La fricción de escribir es la causa más común de consultas incompletas.
Hay barrera de alfabetización digital	Un segmento de clientes no escribe cómodo en un teclado de celular pero manda audios todo el día. La voz amplía la base atendible sin cambiar el producto.
El canal ya es de voz	Si el cliente hoy llama por teléfono, automatizar en voz elimina la espera sin obligarlo a cambiar de hábito.

Dónde la voz destruye valor

Situación operativa	Por qué conviene texto
La respuesta contiene datos que se copian	Un número de seguimiento dictado hay que anotarlo a mano. En texto se copia y se pega. La voz obliga al cliente a un trabajo que el texto no le pedía.
La respuesta es una enumeración	Tres condiciones de garantía leídas en voz alta se olvidan antes de terminar. El oyente no puede releer.
El entorno es ruidoso o público	El cliente no puede escuchar, y la transcripción de su audio se degrada.
El caso requiere evidencia escrita	Un reclamo formal necesita registro legible. El audio complica la trazabilidad y la auditoría.


La fatiga cognitiva: el costo que no aparece en la factura

Este es el punto que decide el diseño del prompt y no solo el del circuito. Al escuchar, la persona sostiene toda la información en memoria de trabajo, que es limitada y no se puede rebobinar. Tres consecuencias operativas, todas implementadas en este circuito:

Restricción cognitiva	Decisión de diseño adoptada
El oyente no puede releer	Una sola idea por respuesta. Si el caso exige más, se ofrece continuar en un segundo mensaje en lugar de encadenar.
Las listas no se retienen habladas	Prohibición explícita de viñetas, guiones y enumeraciones en el System Prompt: además de no retenerse, los símbolos se leen en voz alta.
Los números en cifras se pronuncian mal	Instrucción de escribir los números como se dicen: "diez días corridos" y no "10 días". Un plazo mal pronunciado es un plazo mal entendido.
La cita de fuente es ruido hablado	El agente no dicta "Manual de Políticas, sección cuatro punto uno". La trazabilidad queda en el log de la ejecución, no en el oído del cliente.

Criterio de decisión para este caso. En atención al cliente de e-commerce la voz conviene en la **entrada** y es discutible en la **salida**. Recibir la consulta hablada baja la fricción y mejora la calidad de lo que el cliente cuenta; devolver la respuesta hablada obliga a comprimir a 200 caracteres información que muchas veces necesita más. La implementación entrega voz porque la consigna pide un circuito cerrado, pero **la recomendación profesional es híbrida: escuchar en voz y responder en voz y texto simultáneamente**, para que el dato quede copiable y el tono siga siendo humano.


2 · El circuito



Circuito completo: rama principal de voz, rama de contingencia, subnodos del agente y alternativa de transcripción desactivada.

2.1 · Interceptación binaria de entrada

El trigger escucha los mensajes del bot oficial de Telegram. La descarga del binario se hace en un segundo nodo y no en el trigger, por una razón deliberada: Telegram no entrega el audio en la notificación, sino un identificador de archivo. Separar la notificación de la descarga permite que el circuito decida si vale la pena traer el binario antes de traerlo, y mantiene el payload pesado fuera del disparador.




Trigger del bot oficial de Telegram, escuchando mensajes entrantes.

2.2 · Oídos del agente: OpenAI Whisper

Conector acoplado inmediatamente después de la descarga, con los dos parámetros que la consigna exige de forma estricta:

Parámetro	Valor	Función
Input Binary Property	data	Nombra la propiedad binaria que contiene el audio descargado de Telegram.
Language of the Audio File	es	Fija el idioma en lugar de detectarlo. Evita el paso de detección automática, reduce la latencia y elimina los errores de transcripción por confusión de idioma en audios cortos o con ruido.

Nota de interfaz: en la versión instalada de n8n el campo figura como "Input Data Field Name" en lugar de "Input Binary Property". Es el mismo parámetro, renombrado en la interfaz.




Nodo OpenAI Whisper: operación Transcribe a Recording, propiedad binaria data e idioma es fijado manualmente.

2.3 · Condición de contingencia

Inmediatamente después de Whisper, un IF desvía el flujo cuando la transcripción no es utilizable. No alcanza con verificar que el texto no esté vacío: un audio de ruido puro suele producir una transcripción de una o dos palabras sin sentido, que no está vacía y que el agente trataría como una consulta legítima. Por eso son tres condiciones combinadas con Y:

Condición	Qué falla detecta
El texto no está vacío	Audio corrupto o silencio absoluto
Al menos 4 caracteres	Transcripción de un sonido aislado
Al menos 2 palabras	Ruido de fondo interpretado como una palabra suelta

La rama negativa no falla en silencio: le avisa al cliente que no se entendió el audio y le ofrece dos salidas concretas —grabar de nuevo o escribir—. Un sistema que ignora un mensaje que no entendió es peor que uno que lo admite.



Condición de contingencia posterior a Whisper: tres verificaciones combinadas para descartar audios corruptos y ruido.

2.4 · Cerebro: el agente en modo Tools Agent

La salida de texto limpia de Whisper entra al agente, que conserva la herramienta de base documental del Módulo 5. La continuidad importa: el circuito de voz no es un sistema nuevo sino un canal nuevo sobre el mismo cerebro, con las mismas fuentes y las mismas reglas de fundamentación.


2.5 · Contención financiera: la regla de los 200 caracteres, por duplicado

La consigna pide una instrucción explícita en el System Prompt que limite las respuestas a 200 caracteres, para proteger el conteo de caracteres de la API de síntesis de voz. Está incluida de forma textual e imperativa.

Pero una instrucción en lenguaje natural es una recomendación, no una garantía. Si el modelo se excede, el costo lo paga la API de audio, y nadie se entera hasta la factura. Por eso el circuito agrega un **segundo control por código**, inmediatamente después del agente:

Control	Naturaleza	Qué garantiza
Regla en el System Prompt	Instrucción	Que el agente <i>intente</i> respuestas breves y las redacte pensadas para ser breves
Nodo de blindaje	Código	Que ninguna respuesta supere los 200 caracteres, obedezca el modelo o no

El corte no es ciego: busca el último final de oración antes del límite, para no entregar a la síntesis una frase partida al medio. Y registra tres datos por ejecución —caracteres finales, caracteres crudos y si hubo truncado—, que es lo que permite después medir con qué frecuencia el modelo desobedece la instrucción. Sin ese registro, la regla del prompt es una creencia; con él, es un indicador.




System Message del agente con la regla imperativa de 200 caracteres y las pautas de diseño conversacional para voz.

2.6 · Voz del agente: ElevenLabs

Modelo `eleven_multilingual_v2` , el avanzado multilingüe que pide la consigna. Parámetros de voz calibrados con criterio de atención al cliente:

Parámetro	Valor	Justificación
Stability	0,45	Por debajo de la mitad, a propósito. Los valores altos producen una lectura plana; una voz robótica dictando una política de devolución transmite que nadie se hizo cargo del caso.
Similarity boost (la "Clarity" de la consigna)	0,80	Alto. Prioriza inteligibilidad sobre expresividad. Estas respuestas dictan plazos y cifras: si el número no se entiende, la respuesta no sirve.
Style	0	Sin exageración interpretativa. Es el parámetro que más riesgo tiene de alterar la pronunciación de cifras.
Speaker boost	activado	Mejora la consistencia de la voz entre respuestas.
Speed	1,0	Neutro. Acelerar degrada justamente la comprensión de los números.

Nota de interfaz: el nodo de comunidad expone estos parámetros como un objeto JSON y no como sliders visuales. Es una diferencia de presentación, no de configuración.



Nodo de ElevenLabs: modelo `eleven_multilingual_v2` y parámetros de voz calibrados.


3 · Protocolo de privacidad de los binarios de voz

La voz de una persona es un dato biométrico. No es un archivo de audio: es un identificador capaz de autenticar a alguien. Un sistema que conserva las notas de voz de sus clientes acumula un pasivo que no necesita.

El circuito implementa dos controles, y conviene distinguir cuál es el que realmente protege:

Control	Jerarquía	Qué hace
Configuración del workflow No guardar datos de ejecuciones exitosas ni fallidas, ni de ejecuciones manuales	Principal	n8n no persiste ningún payload de estas ejecuciones. Los binarios viven exclusivamente en la memoria volátil del proceso durante la ejecución y se liberan al terminar. Este es el control que protege.
Nodos de purga Presentes en la rama exitosa y en la de contingencia	Complementario	Devuelven un objeto nuevo sin la propiedad binaria, de modo que el audio no viaja adherido al resultado. Documentan la intención de forma visible en el lienzo.

El audio descartado por ruido también se purga: **un audio corrupto sigue siendo la voz de una persona**. Es la clase de detalle que se olvida cuando la privacidad se piensa solo sobre el camino feliz.



Configuración del workflow: no se persisten datos de ejecuciones. Es el control principal de privacidad de los binarios de voz.


4 · Alternativa sin costo, documentada en el lienzo

El nodo nativo de transcripción de n8n tiene el modelo `whisper-1` fijo y no admite apuntar a otro proveedor. Whisper en OpenAI no tiene capa gratuita. Para un sistema que debe correr sin costo, eso es un bloqueo real.

La salida es un HTTP Request a **Groq**, que sirve el mismo modelo Whisper Large v3 con capa gratuita y sin tarjeta, devolviendo el texto en la misma propiedad `text`, de modo que el resto del circuito no cambia. El nodo

queda en el lienzo, desactivado y documentado.

Vía	Costo	Cuándo usar cada una
Nodo nativo OpenAI Whisper	Requiere crédito cargado	Producción con volumen, donde importa el soporte del proveedor y la integración nativa
HTTP Request a Groq	Capa gratuita	Desarrollo, demostración y operación de bajo volumen. Mismo modelo, latencia menor.



Alternativa sin costo, desactivada y documentada en el lienzo: mismo modelo Whisper Large v3 servido por Groq.

5 · Limitaciones declaradas

Lo que este entregable presenta es la configuración visual del circuito, que es lo que la consigna pide. Lo que no presenta, y por qué:

Limitación	Causa y vía de resolución
El circuito no se ejecutó de extremo a extremo	El Telegram Trigger registra su webhook contra la URL pública de la instancia. n8n corre self-hosted en localhost, de modo que Telegram no puede entregar los mensajes entrantes. Se resuelve exponiendo la instancia mediante un túnel y declarando esa URL como webhook base. No se aplicó dentro del plazo de esta entrega por el riesgo de alterar la configuración del container que aloja los workflows de los seis módulos anteriores.
Parámetros de voz como JSON	El nodo de ElevenLabs es de comunidad y expone las palancas de voz como objeto JSON en lugar de sliders. La configuración es equivalente.
Modelo de transcripción fijo	El nodo nativo no permite seleccionar proveedor. Documentado arriba, con la alternativa implementada en el lienzo.
Voz genérica	Se usa una voz del catálogo. Una identidad sonora propia requiere clonación, que no está incluida en la capa gratuita y además exige consentimiento explícito de la persona cuya voz se clona.

Próximo paso definido

La versión operativa del circuito —túnel activo, transcripción por Groq, síntesis por ElevenLabs en capa gratuita — queda como continuación inmediata y no como una intención vaga: los dos caminos ya están contruidos en el mismo lienzo, y pasar de uno a otro es activar un nodo y desactivar el otro. Esa comparación entre **la implementación que sigue la consigna y la optimizada para costo cero** es, además, la medición más útil que puede salir de este módulo.

Anexo · Versión operativa

Esta sección documenta el trabajo posterior a la entrega. El circuito descrito arriba quedó **funcionando de extremo a extremo**, con costo cero de operación: el cliente manda una nota de voz por Telegram y recibe una respuesta hablada, fundada en la base documental.

Qué cambió y por qué

Cambio	Motivo	Consecuencia
Transcripción por Groq el nodo de OpenAI Whisper quedó desactivado en el lienzo	Whisper en OpenAI no tiene capa gratuita. Groq sirve el mismo modelo Whisper Large v3 sin costo y sin tarjeta.	Se invirtieron los roles respecto de la entrega: la vía documentada pasó a ser la operativa, y la nativa quedó como referencia.
Nodo de normalización de entrada	Telegram entrega las notas de voz como <code>.oga</code> . Groq valida la extensión contra una lista cerrada que incluye <code>ogg</code> pero no <code>oga</code> , aunque el contenedor es el mismo.	Se renombra el binario sin tocar los bytes.
Nodo de normalización de salida	El nodo de ElevenLabs rotula su salida como <code>audio.textToSpeech.mp3</code> con mime <code>audio/mp3</code> sin importar el Output Format elegido . Con OPUS seleccionado, los bytes son Opus pero la etiqueta dice mp3.	Telegram decidía el formato de presentación por la etiqueta y mostraba un archivo adjunto en lugar de una nota de voz.
Banco de pruebas	El Telegram Trigger necesita una URL pública para registrar su webhook, y la instancia corre en localhost.	Permitió validar el 100% de la cadena de audio sin modificar la infraestructura.

El hallazgo que más tiempo ahorra a quien repita esto. Para que Telegram muestre una nota de voz real —la burbuja con la onda— y no un archivo adjunto, **no hace falta el método `sendVoice`**, que el nodo nativo de n8n no implementa y que obligaría a un HTTP Request con el token del bot expuesto en la URL. Alcanza con **corregir el mime del binario a `audio/ogg`** antes de enviarlo con el nodo nativo: Telegram decide cómo renderizar por la etiqueta declarada, no por el método.

La primera hipótesis —cambiar el método de envío— era la costosa: exponía un secreto en el workflow, que además se publica en un repositorio abierto. La solución correcta resultó ser la barata y no requiere tocar credenciales.


Validación sin infraestructura pública

Para probar la cadena completa sin exponer la instancia se usó una propiedad de la API de Telegram: mientras no haya un webhook registrado, los mensajes recibidos por el bot quedan disponibles durante veinticuatro horas y se pueden consultar desde el navegador. De ahí se obtiene el identificador del archivo de audio, y un par de nodos lo inyectan en el circuito en lugar del trigger.

Las expresiones aguas abajo usan un ternario sobre `isExecuted`, de modo que el banco de pruebas y el trigger real conviven sin desarmar nada: el mismo circuito funciona con cualquiera de los dos orígenes.



Ejecución completa del circuito: descarga del binario, transcripción por Groq, agente con base documental, síntesis y envío.



Resultado en el cliente: la respuesta del agente llega como nota de voz reproducible, no como archivo adjunto.

Costo real de la operación

Componente	Proveedor	Costo
Transcripción (STT)	Groq — Whisper Large v3	Capa gratuita, sin tarjeta
Agente y embeddings	Google Gemini Flash Lite	Capa gratuita, 20 solicitudes diarias por modelo
Síntesis de voz (TTS)	ElevenLabs Multilingual v2	Plan Free, 10.000 créditos mensuales
Orquestación	n8n self-hosted	Infraestructura propia

Con respuestas limitadas a doscientos caracteres, los diez mil créditos mensuales de la capa gratuita de síntesis alcanzan para unas cincuenta respuestas habladas. **Es suficiente para una demostración y para un piloto de bajo volumen; no lo es para producción**, y ese es el límite real que define cuándo hay que pasar a un plan pago. El cuello de botella no es el agente ni la transcripción: es la voz.

Lo que falta

Una sola cosa: **el trigger automático**. Hoy la ejecución se dispara a mano. Para que el bot responda solo, la instancia necesita una URL pública declarada como `WEBHOOK_URL`, lo que implica recrear el container. Está pendiente por decisión de riesgo, no por desconocimiento: ese container aloja los workflows de los nueve módulos y una variable de entorno mal puesta ya dejó la instancia inaccesible una vez durante este curso.

En la misma operación se incorporará el token del bot como variable de entorno, de modo que cualquier llamada directa a la API de Telegram pueda referenciarlo con `{{ $env.TELEGRAM_BOT_TOKEN }}` en lugar de escribirlo en el workflow. El JSON publicado en el repositorio no contiene ningún secreto.

6 · Conclusión

El aporte de este checkpoint no es técnico sino de criterio. Conectar Whisper y ElevenLabs es mecánico; lo que define si el canal de voz sirve es haber decidido **qué no debe decirse hablado**: sin listas, sin cifras en números, sin citas de sección, una idea por respuesta y doscientos caracteres de techo, con un control por código que garantice ese techo cuando la instrucción no alcance.

La conclusión operativa del análisis de viabilidad es la que un cliente necesitaría escuchar antes de aprobar el proyecto: **en atención al cliente, la voz conviene claramente en la entrada y solo condicionalmente en la salida**. La recomendación profesional es un canal híbrido — escuchar en voz, responder en voz y texto a la vez —, de modo que el dato quede copiable y el tono siga siendo humano.