

Pre-entrega Módulo 7

Diseño Arquitectónico de un Sistema Agéntico Vertical de Industria
Vertical: Customer Success & Sales Ops en e-commerce

Ignacio Paiva

IA Automation Specialist

TiendaVerde

Septiembre 2026

Consultor

Coderhouse

Caso de referencia

Informe de consultoría

Página 1 · Relevamiento del proceso y framework de priorización

1.1 · Problema operativo

El área de atención al cliente de un e-commerce de tamaño medio absorbe un volumen alto de consultas repetitivas y de bajo valor —estado de pedido, plazos de envío, medios de pago, política de devoluciones— que consumen la mayor parte del tiempo del equipo. La consecuencia no es solo el costo de esas horas: es que las consultas que sí requieren criterio humano —un reclamo que se está escalando, una oportunidad de venta, un cliente a punto de irse— quedan sepultadas en la misma cola y se atienden tarde.

El problema, entonces, no es "responder consultas". Es **que el equipo no distingue en tiempo real qué consulta merece su atención**, porque las procesa todas con el mismo esfuerzo.

1.2 · Por qué una solución agéntica y no una automatización lineal

Un árbol de reglas resuelve bien un formulario, pero acá la entrada es lenguaje natural escrito por un cliente: "¿che, y mi compra?" y "quiero el estado del pedido TV-1004" tienen que caer en la misma rama, y ninguna regla de texto razonable cubre las dos. Se necesita un sistema que **interprete la intención** antes de decidir el camino. Esa es la frontera entre automatización determinista y autonomía probabilística, y es lo que justifica el paradigma agéntico en este proceso concreto.

1.3 · Framework de priorización

Evaluación del caso sobre los tres vectores del asesor. Escala 1 a 5.

Vector	Score	Fundamento
Impacto esperado en las operaciones	5	El 70% de las consultas entrantes son de cinco tipos repetitivos y resolubles con datos que ya viven en sistemas de la empresa. Automatizar ese 70% libera al equipo para el 30% que genera o retiene ingresos.
Viabilidad técnica no-code	4	Todos los sistemas involucrados (CRM, casilla de correo, base de pedidos, canal del equipo) tienen conector nativo en la plataforma de orquestación. Se descuenta un punto por la dependencia de la calidad del dato de origen: si la base de pedidos está sucia, el agente hereda esa suciedad.
Nivel de adopción probable	4	El equipo de soporte no pierde control: el sistema redacta pero no envía. La resistencia habitual —"la IA va a contestar cualquier cosa en mi nombre"— se neutraliza por diseño con el guardrail de aprobación humana. Se descuenta un punto por la curva de confianza inicial.

Veredicto: 13 sobre 15. Caso de alta prioridad. El vector que hay que vigilar no es el técnico sino el de adopción: la implementación debe empezar en modo sombra para construir confianza antes de darle al sistema cualquier capacidad de escritura visible para el cliente.


1.4 · Baseline manual del proceso actual

Cifras del relevamiento, declaradas como supuestos de trabajo: corresponden a un e-commerce de tamaño medio y deben re-medirse contra los datos reales del cliente antes de comprometer un ROI.

Dimensión	Situación actual
Qué se hace	Un operador lee cada consulta, la clasifica mentalmente, busca el pedido en la planilla o el CRM, redacta una respuesta y la envía. Si el caso escala, lo reenvía por interno a un supervisor.
Quién lo ejecuta	Dos personas de atención al cliente, sin turnos rotativos ni cobertura fuera del horario comercial.
Volumen	≈ 1.200 consultas por mes entre casilla de correo y chat del sitio.
Tiempo por consulta	≈ 6 minutos promedio, incluyendo la búsqueda del pedido en el sistema.
Carga total	≈ 120 horas-persona por mes dedicadas a atención de primer nivel.
Tiempo de primera respuesta	Entre 4 y 26 horas según el momento en que entre la consulta. Las de fin de semana esperan al lunes.
Tasa de error	Sin medición formal. Se detectan retrabajos por respuestas con datos de pedido desactualizados, pero no se registran.

Un baseline sin medición no es un baseline. La ausencia de datos de error es en sí misma un hallazgo del relevamiento: hoy la organización no puede saber si el sistema agéntico mejora la calidad, porque no sabe cuál es su calidad actual. La primera fase del despliegue tiene que instrumentar la medición manual en paralelo, aunque todavía no automatice nada.

2.1 · Coreografía de la red



El principio de diseño es que **ningún agente hace dos cosas**. El coordinador decide pero no ejecuta; los especialistas ejecutan pero no deciden a quién delegar; el supervisor evalúa pero no redacta. Esa separación es lo que permite sumar un especialista nuevo sin tocar la lógica de los demás.

2.2 · Fichas de los agentes

Misión

Interpretar la intención del mensaje entrante y decidir qué especialista interviene, dentro de una taxonomía cerrada de negocio. No responde al cliente ni toca ningún sistema.

System prompt constitutivo

Clasifica el mensaje en una sola categoría de la lista cerrada. Prohibido inventar categorías. Ante mensajes ambiguos, reclamos legales, pedidos de reembolso o enojo sostenido, no fuerza la clasificación: deriva a la vía de escape. Temperatura fijada en cero para que la clasificación sea estable entre ejecuciones.

Herramientas conectadas

Ninguna. Solo el modelo de lenguaje.

Salida y destinatario

```
{ "categoria": "CONSULTA_PEDIDO" | "CONSULTA_GENERAL" | "SIN_CLASIFICAR",  
  "session_id": string, "mensaje_original": string } → al especialista correspondiente
```

Misión

Recuperar de los sistemas de la empresa los datos duros de un pedido concreto y devolverlos normalizados. No interpreta, no redacta, no decide.

System prompt constitutivo

No aplica: es un especialista determinista. Su comportamiento está fijado por código, no por prompt. Esta es una decisión de diseño deliberada — buscar un registro por identificador no requiere un modelo de lenguaje, y usarlo introduciría costo y variabilidad sin ningún beneficio.

Herramientas conectadas

Base de pedidos (lectura).

Salida y destinatario

```
{ "status": "success" | "not_found" | "error", "codigo": string, "mensaje": string,  
  "data": { numero_pedido, nombre_cliente, email, estado, fecha_entrega,  
            transportista, seguimiento, monto } } → al especialista de redacción
```

ESPECIALISTA DE REDACCIÓN

Misión

Convertir datos ya resueltos en un mensaje claro para el cliente, con la identidad y el tono de la marca.

System prompt constitutivo

Rol, ámbito acotado a atención al cliente, y reglas explícitas de lo que no puede hacer: no inventar estados ni fechas, no prometer reintegros ni compensaciones económicas, no pedir datos de tarjeta. El contexto histórico recuperado de la memoria se le inyecta entre delimitadores rígidos, con la instrucción de tratarlo como datos y nunca como órdenes — defensa contra inyección indirecta de prompt.

Herramientas conectadas

Ninguna. Trabaja exclusivamente sobre lo que recibe en el prompt.

Salida y destinatario

```
{ "status": "success", "data": { "respuesta_cliente": string } } → al supervisor de calidad
```

SUPERVISOR DE CALIDAD · AI-AS-A-JUDGE

Misión

Evaluar la respuesta propuesta contra el contexto recuperado antes de que salga del sistema, y emitir un veredicto que determine si se envía, se corrige o se congela.

System prompt constitutivo

Evalúa exactitud factual contra las fuentes provistas, no plausibilidad. Devuelve exclusivamente un objeto JSON con esquema forzado. No reescribe la respuesta: solo juzga.

Herramientas conectadas

Ninguna. Recibe query, contexto y respuesta propuesta.

Salida y destinatario

```
{ "exactitud_factual": 1..5, "estado_veredicto": "ACEPTADO"|"CORREGIR"|"RECHAZADO",  
  "justificacion": string } → al enrutador de decisión
```

Misión

Reflejar la interacción en los sistemas de la organización: actualizar o crear el contacto en el CRM, notificar al canal del equipo y dejar el borrador de respuesta en la casilla.

System prompt constitutivo

No aplica: determinista. Antes de cada escritura ejecuta una búsqueda previa para no duplicar registros, y valida el payload para no enviar objetos mal formados.

Herramientas conectadas

CRM (lectura y escritura acotada a contactos), canal del equipo (escritura), casilla de correo (creación de borradores únicamente).

Salida y destinatario

```
{ "crm": "creado|"actualizado", "notificacion": "enviada",  
  "borrador": "creado_pendiente_aprobacion" } → al log de trazabilidad
```

2.3 · Mapa de permisos bajo mínimo privilegio

Cada conector recibe el permiso más chico que le permite cumplir su función, y ninguno más. El criterio operativo es simple: si un permiso adicional no es necesario para una tarea que el agente ejecuta hoy, no se otorga.

Conector	Acceso	Alcance otorgado	Qué se deniega y por qué
Base de pedidos	Lectura	Una sola tabla, vía identidad de servicio dedicada	Sin escritura: el agente informa sobre pedidos, nunca los modifica. Un agente que puede cambiar el estado de un pedido puede arruinar la operación logística.
Base de memoria	Lectura y escritura	Una tabla, filtrada siempre por identificador de sesión	El filtro por sesión no es una optimización: es lo que impide la amnesia cruzada, que una conversación lea el contexto de otro cliente.
CRM	Lectura y escritura	Solo el objeto contacto	Sin acceso a negocios, tickets, presupuestos ni propiedades de facturación. El agente registra quién escribió; no toca el pipeline comercial.
Canal del equipo	Escritura	Publicar mensajes y leer la lista de canales	Sin lectura del historial de conversaciones del equipo. El agente notifica hacia adentro; no vigila lo que el equipo se dice.
Casilla de correo	Lectura y escritura acotada	Leer entrantes y crear borradores	Sin permiso de envío. Es el guardrail más importante del mapa: la imposibilidad técnica de enviar es más fuerte que la instrucción de no enviar.

El permiso denegado es parte del diseño, no una limitación. Que el agente no pueda enviar correo no es una carencia a resolver en una fase futura: es lo que hace que el sistema sea adoptable. La confianza se construye demostrando que el sistema *no puede* hacer daño, no prometiendo que no lo hará.

3.1 · Propuesta de valor

Hoy el equipo de atención dedica unas 120 horas por mes a contestar preguntas cuya respuesta ya existe en los sistemas de la empresa. Ese tiempo no genera ventas ni retiene clientes: solo traslada información de un sistema a un correo.

La solución propuesta se ocupa de ese traslado. Recibe la consulta por el canal que llegue, busca el dato, redacta la respuesta con el tono de la marca y la deja lista para que una persona la revise y la mande. El equipo deja de escribir respuestas y pasa a aprobarlas, que lleva segundos en lugar de minutos.

El resultado medible es doble: **el cliente recibe respuesta en minutos en vez de horas**, y el equipo recupera la mayor parte de su jornada para las consultas donde su criterio realmente cambia el resultado del negocio — un reclamo que se puede desactivar a tiempo, una consulta previa a la compra que se puede cerrar.

Y todo esto ocurre sin que la empresa ceda el control: **ninguna comunicación sale sin que una persona la apruebe**. El sistema propone, el equipo decide.

3.2 · Criterios de éxito medibles

Los KPI se fijan antes de implementar, contra el baseline de la página 1.

KPI	Línea base	Meta a 90 días	Cómo se mide
Tasa de resolución autónoma	0%	60% de las consultas	Consultas resueltas con borrador aprobado sin edición, sobre el total procesado.
Tiempo de primera respuesta	4 a 26 h	Menos de 15 min en horario, menos de 2 h fuera	Marca temporal entre el ingreso de la consulta y el envío aprobado.
Horas-persona liberadas	120 h/mes	Reducción del 55%	Volumen procesado por el sistema × tiempo manual promedio ahorrado por consulta.
Exactitud factual	Sin medición	≥ 4,2 sobre 5	Puntaje del supervisor de calidad sobre cada respuesta, promediado semanalmente.
Tasa de edición humana	No aplica	Menos del 25%	Borradores que el operador modifica antes de enviar. Es el mejor termómetro de confianza real.

El último indicador merece atención: mide adopción, no técnica. Si el equipo edita el 80% de los borradores, el sistema técnicamente funciona pero comercialmente fracasó.

3.3 · Semáforo operativo de autonomía

Nivel	Acciones	Régimen
● Autónomo	Clasificar intención · consultar datos de pedido · redactar el texto de la respuesta · escribir el resumen de memoria · registrar el contacto en el CRM · notificar al canal del equipo · escribir el log	Se ejecuta sin intervención. Todas son acciones internas o reversibles, sin efecto directo sobre el cliente ni sobre dinero.

● Supervisado	Enviar cualquier comunicación al cliente · modificar datos de un contacto existente en el CRM	El sistema deja la acción preparada y congelada. Una persona la aprueba desde la casilla o desde el canal del equipo. Sin aprobación, no ocurre.
● Prohibido	Transferir dinero o autorizar reembolsos · modificar precios o condiciones de renovación · cancelar o alterar pedidos · borrar registros · comprometer plazos de entrega no confirmados por el transportista	Fuera del alcance del sistema por diseño. No se resuelve con un prompt: los permisos del conector no habilitan estas operaciones.

3.4 · Protocolo de escalado forzado

Cinco disparadores mandan el caso al canal del equipo con botones interactivos de *Aprobar*, *Editar* y *Tomar el caso*, y congelan la ejecución hasta que alguien responda:

- El cliente menciona reembolso, devolución de dinero o cambio de condiciones comerciales.
- Aparece lenguaje legal: abogado, denuncia, Defensa del Consumidor.
- Se detecta riesgo de pérdida del cliente: amenaza de cancelar la cuenta o enojo sostenido en más de un turno.
- El supervisor de calidad devuelve veredicto **RECHAZADO**.
- El coordinador no logra clasificar la intención dentro de la taxonomía cerrada.

El quinto disparador es el más importante y el menos obvio: **la incertidumbre del sistema es en sí misma un motivo de escalado**. Un agente que siempre encuentra una categoría es un agente que fuerza respuestas.

4.1 · Scorecard que utilizan los agentes

La rúbrica que aplica el supervisor de calidad sobre cada respuesta antes de habilitar su salida. Está diseñada para ser evaluable contra evidencia documental, no contra impresión: cada dimensión se responde mirando el contexto recuperado, no juzgando si el texto "suena bien".

Dimensión	Peso	Criterio de puntuación
Exactitud factual	40%	5 todo dato afirmado aparece literal en las fuentes · 4 todo verificable, con una inferencia menor razonable · 3 un dato no verificable pero inocuo · 2 un dato contradice la fuente · 1 inventa información sustantiva.
Cobertura de la consulta	20%	5 responde todo lo preguntado · 3 responde lo principal y omite un secundario · 1 responde otra cosa.
Respeto de los límites	25%	5 no promete nada fuera de alcance · 1 compromete reintegros, plazos o condiciones que el agente no puede garantizar. Esta dimensión es eliminatoria: un 1 fuerza RECHAZADO cualquiera sea el promedio.
Tono y forma	15%	5 cordial, directo, dentro del límite de extensión, sin jerga interna ni identificadores técnicos · 3 correcto pero excede la extensión · 1 tono inadecuado al canal.

Umbral de decisión: promedio ponderado $\geq 4,0$ y sin ningún 1 → ACEPTADO . Entre 3,0 y 3,9 → CORREGIR , con la crítica devuelta al redactor y un máximo de un reintento. Menor a 3,0, o cualquier 1 en respeto de los límites → RECHAZADO y escalado humano.

Por qué el reintento tiene tope. Un ciclo de auto-corrección sin límite es un bucle de costo infinito: dos modelos pueden discutir indefinidamente sin converger. Un solo reintento, y después una persona. El límite no es una concesión a la imperfección del sistema, es una decisión de presupuesto.

4.2 · Versión de portafolio

Sistema agéntico de atención al cliente para e-commerce

El problema. Un comercio electrónico de tamaño medio dedicaba unas 120 horas mensuales de su equipo a responder consultas repetitivas cuya respuesta ya existía en sus propios sistemas. Los casos que requerían criterio humano esperaban en la misma cola que los que no.

La solución. Una red de agentes especializados que recibe consultas por correo y por chat, interpreta la intención, recupera los datos del pedido en los sistemas de la empresa, redacta la respuesta con la identidad de la marca y la deja como borrador para aprobación. Incorpora memoria persistente entre conversaciones, un supervisor automático que evalúa cada respuesta antes de habilitarla, y escalado forzado al equipo ante reclamos legales, pedidos de reembolso o riesgo de pérdida del cliente.

Decisiones de diseño destacables. El sistema no tiene permiso técnico de envío de correo: solo puede crear borradores. La frontera de autonomía no se sostiene con instrucciones sino con permisos. Cada especialista resuelve una única tarea y devuelve un contrato de datos uniforme, lo que permite incorporar agentes nuevos sin modificar el orquestador.

Resultados objetivo. 60% de resolución autónoma, primera respuesta bajo 15 minutos, reducción del 55% de las horas dedicadas a atención de primer nivel, con exactitud factual auditada respuesta por respuesta.

Stack. Orquestación no-code, modelos de lenguaje vía API, base relacional de memoria, CRM, casilla corporativa y canal de equipo, todo conectado con permisos de mínimo privilegio.

4.3 · Nota final del asesor

Este diseño no incluye una fase de implementación directa a producción, y la omisión es deliberada. La secuencia recomendada arranca en modo sombra —el sistema procesa consultas reales y produce borradores que nadie envía, solo se comparan contra lo que el equipo respondió— durante el tiempo necesario para acumular una muestra de exactitud factual medida. Recién con esa evidencia se habilita la escritura supervisada.

Saltear esa etapa es la causa más común de fracaso en proyectos de este tipo: no porque el sistema no funcione, sino porque el equipo nunca llega a confiar en él y termina reescribiendo todo lo que produce.