

Pre-entrega Módulo 9

Plan de Gobernanza, Gestión y Monitoreo Financiero de IA

Ignacio Paiva
Consultor

IA Automation Specialist
Coderhouse

TiendaVerde
Sistema en evaluación

Septiembre 2026
Plan de gestión ejecutiva

Este plan se elabora sobre un sistema agéntico real y en funcionamiento: la red multi-agente de atención al cliente construida a lo largo del programa. Las cifras de consumo no son estimaciones teóricas — están **medidas en el panel de ejecución de la plataforma** durante las pruebas de los módulos anteriores. Los precios de los proveedores corresponden a septiembre de 2026 y se citan al pie.

Dimensión 1 · Planificación financiera y economía del token

1.1 · KPIs de negocio para dirección

Indicadores comprensibles sin conocimiento técnico, cada uno con su baseline y su fuente de medición.

KPI	Baseline	Meta 90 días	Fuente del dato
Tasa de resolución autónoma	0%	60%	Borradores aprobados sin edición / total procesado. Se registra en el log de cada ejecución.
Tiempo operativo ahorrado	120 h/mes manuales	−55% (≈66 h)	Volumen procesado × tiempo manual promedio por consulta.
Tiempo de primera respuesta	4 a 26 h	<15 min en horario	Diferencia entre marca de ingreso y marca de envío aprobado.
Satisfacción del usuario	Sin medición	≥ 4,3 / 5	Encuesta de una pregunta en el pie de cada respuesta enviada.
Reducción de errores manuales	Sin medición	Establecer la línea base	Exactitud factual del supervisor automático, promediada semanalmente.

Dos KPI arrancan sin baseline, y eso es un hallazgo. La organización no mide hoy ni satisfacción ni tasa de error. La primera fase del despliegue debe instrumentar esa medición aunque todavía no automatice nada: sin línea base no hay forma de demostrar mejora, y un ROI sin baseline es una afirmación, no un cálculo.

1.2 · Matriz de Costo Total de Operación

Consumo medido por ejecución

Cada consulta completa dispara hasta tres llamadas a modelos de lenguaje: clasificación de intención, redacción de la respuesta y —a partir del sexto intercambio de una sesión— consolidación del resumen de memoria. El consumo observado en el panel de ejecución durante las pruebas se ubicó entre **2.600 y 4.000 tokens por ejecución completa**, con una proporción aproximada de 85% entrada y 15% salida.

Para el cálculo se toma el extremo alto: 4.000 tokens por ejecución (3.400 entrada / 600 salida) y un volumen de 1.200 ejecuciones mensuales.

Escenario de modelo	Entrada	Salida	Costo mensual	Por 1.000 ejec.
Gama económica	4,08 M tokens	0,72 M tokens	USD 1,68	USD 1,40
USD 0,20 / 1,20 por millón	USD 0,82	USD 0,86		

Gama media USD 1 / 5 por millón	4,08 M tokens USD 4,08	0,72 M tokens USD 3,60	USD 7,68	USD 6,40
Gama media con prompt caching lecturas de caché al 10%	USD 1,22 70% del input cacheado	USD 3,60	USD 4,82	USD 4,02

Costo total de operación

Componente	Mensual	Nota
Modelos de lenguaje	USD 2 a 8	Según gama elegida. Es el componente más chico del TCO.
Transcripción de voz	USD 1 a 3	Solo si se habilita el canal de audio, y proporcional a los minutos procesados.
Síntesis de voz	USD 0 a 5	Capa gratuita suficiente para volúmenes bajos.
Base de conocimiento documental	USD 0 a 10	Capa gratuita alcanza para una base fija; escala con el volumen de documentos, no de consultas.
Base de memoria relacional	USD 0 a 20	Capa gratuita alcanza en esta escala.
Infraestructura de orquestación	USD 15 a 30	Servidor propio o instancia gestionada. Es el componente dominante del TCO.
TCO mensual estimado	USD 20 a 75	

La conclusión financiera es contraintuitiva y conviene decirla sin adornos: el token no es el problema. En esta escala, los modelos representan menos del 15% del costo operativo. El gasto real está en la infraestructura que sostiene la orquestación, y sobre todo en las **horas de implementación y mantenimiento**, que no aparecen en ninguna factura de proveedor. Presentar a la dirección un análisis centrado en el precio del token sería preciso en el dato y equivocado en el foco.

1.3 · ROI y caso de negocio

Supuestos declarados: costo cargado de hora-persona de soporte USD 8; esfuerzo de implementación 60 horas de consultoría a USD 40. Ambos deben re-validarse con las cifras reales del cliente antes de comprometer el retorno.

Concepto	Cálculo	Valor
Horas manuales evitadas por mes	120 h × 55%	66 h
Ahorro mensual en costo de labor	66 h × USD 8	USD 528
Costo operativo mensual del sistema	TCO	USD 20 a 75
Beneficio neto mensual	528 – 75 (caso conservador)	USD 453
Inversión inicial de implementación	60 h × USD 40	USD 2.400
Periodo de repago	2.400 / 453	≈ 5,3 meses
ROI a 12 meses	(453 × 12 – 2.400) / 2.400	127%

Al ahorro de labor se suma un beneficio que no se cuantifica acá pero conviene declarar: la **capacidad de absorber picos de demanda** sin contratar. En temporada alta el volumen de consultas se duplica; el sistema absorbe ese salto sin costo marginal relevante, mientras que el equipo humano no.

1.4 · Control preventivo del gasto

El riesgo financiero de un sistema agéntico no es el costo esperado, que es bajo y predecible. Es el **costo accidental**: un bucle lógico que llama al modelo mil veces en una noche. Cuatro controles preventivos:

Control	Implementación
Separación física de entornos	Dos claves distintas por proveedor: una de desarrollo y una de producción, nunca compartidas. La de desarrollo vive en la instancia local; la de producción solo en el servidor.
Tope duro en desarrollo	Límite de gasto mensual de USD 5 a 10 configurado en el panel del proveedor sobre la clave de desarrollo. Es el cortafuegos contra el bucle accidental durante las pruebas.
Guardrail de iteraciones	Techo de iteraciones fijado en el nodo agéntico. Sin ese límite, un agente que razona mal puede encadenar llamadas indefinidamente dentro de una sola ejecución.
Alerta de umbral	Notificación al canal del equipo cuando el consumo acumulado del mes supera el 70% del presupuesto. Avisa antes del techo, no después.

Estrategias no técnicas de contención

- **Acotamiento del contexto.** La memoria persistida es un resumen consolidado, no la transcripción de la conversación. Esa sola decisión evita que el prompt crezca linealmente con la cantidad de intercambios, que es la causa habitual del costo que se dispara sin que nadie note por qué.
- **Prompt caching.** Los bloques fijos y voluminosos —el system prompt del redactor, el playbook del supervisor, los fragmentos recurrentes de la base documental— se cachean. Las lecturas de caché cuestan una décima parte de la tarifa de entrada, y en este sistema entre el 60% y el 70% del input de cada llamada es texto fijo. Es la palanca de ahorro más grande disponible sin cambiar de modelo.
- **Modelo por tarea.** No todas las llamadas necesitan la misma capacidad. La clasificación de intención y la consolidación del resumen corren en gama económica; solo la redacción de cara al cliente justifica un modelo mejor. La arquitectura ya separa esos nodos, de modo que la optimización es un cambio de credencial, no un rediseño.
- **Disparo condicionado.** La consolidación de memoria se ejecuta a partir del sexto intercambio de una sesión, no en cada mensaje. En una distribución típica de conversaciones cortas, eso elimina la mayoría de las llamadas de resumen.

Dimensión 2 · Logs estructurados y trazabilidad

2.1 · Panel operativo

El dashboard se alimenta de forma nativa desde la orquestación hacia una base relacional no-code, sin herramienta de BI adicional. Una fila por ejecución, y vistas agregadas sobre esa misma tabla.

Bloque del panel	Contenido
Volumen y disponibilidad	Ejecuciones totales, exitosas y fallidas por día. Tiempo medio de ejecución de punta a punta. Distribución por canal de entrada.
Calidad	Exactitud factual media según el supervisor. Distribución de veredictos (aceptado / corregir / rechazado). Tasa de edición humana sobre los borradores.
Autonomía	Porcentaje resuelto sin intervención. Cantidad de escalados y motivo de cada uno.
Economía	Tokens de entrada y salida acumulados. Costo estimado del mes en curso. Costo medio por consulta resuelta.
Enrutamiento	Distribución por categoría de intención, y tasa de fallback. Una tasa de fallback creciente indica que la taxonomía se quedó corta frente a lo que los clientes realmente preguntan.

2.2 · Esquema de logs máquina-procesables

Cada paso relevante emite un objeto JSON con esta estructura fija. La uniformidad es lo que permite consultar el log con filtros en lugar de leerlo.

```
{
  "traceId": "trc_2026-09-09_a40bb7de51ad4bb8",
  "spanId": "spn_04",
  "parentSpanId": "spn_03",
  "timestamp": "2026-09-09T14:32:07.412-03:00",
  "sessionId": "a40bb7de51ad4bb89735a9cb2184ecc3",
  "canal": "email",
  "workflowName": "Manager - Integraciones Reales",
  "nodeName": "Especialista de Redaccion",
  "nodeType": "agent",
  "modelName": "gama-economica-v1",
  "systemPromptSnapshot": "sha256:9f2a...c41b",
  "inputTokens": 2196,
  "outputTokens": 396,
  "latencyMs": 2740,
  "toolCalls": [ { "tool": "consultar_pedidos",
    "input": { "numero_pedido": "TV-1004" },
    "outputStatus": "success",
    "outputSizeBytes": 412 } ],
  "confidenceScore": 4.4,
  "veredictoSupervisor": "ACEPTADO",
  "escalado": false,
  "errorCode": null
}
```

Decisiones de diseño del esquema

- **systemPromptSnapshot** guarda un hash, no el texto. El prompt completo se repetiría en cada registro y multiplicaría el peso del log sin aportar nada. El hash permite responder la pregunta que importa en una

auditoría —"¿con qué versión de las instrucciones se produjo esta respuesta?"— contra un repositorio versionado de prompts, y detecta cualquier cambio no documentado.

- **toolCalls** **registra el tamaño de la salida, no la salida.** Volcar el resultado completo de cada herramienta convertiría el log en una copia de la base de datos. Se registra qué se llamó, con qué parámetros y si funcionó; el dato en sí ya vive en su sistema de origen.
- **confidenceScore** **viene del supervisor, no del modelo.** La autoevaluación de un modelo sobre su propia respuesta no es una métrica confiable. El puntaje que se registra es el que emite un evaluador independiente contra las fuentes recuperadas.

2.3 · Correlación unificada mediante traceId

El `traceId` se genera una sola vez, en el nodo de entrada, y se propaga **manualmente dentro del contrato de datos** hacia cada sub-workflow. Esto es un requisito de implementación, no una función automática: en una arquitectura de sub-workflows independientes, cada flujo hijo tiene su propio identificador de ejecución, y sin un identificador de negocio transversal la traza se corta en cada delegación.

Ejecución del Manager

traceId: trc_2026-09-09_a40bb7de

span 01

Filtro anti auto-reply

parent: -

span 02

Lectura de memoria

parent: 01

span 03

Coordinador de triaje

parent: 02

span 04

Especialista de datos

parent: 03

← sub-workflow

span 05

Consulta a base

parent: 04

span 06

Especialista de redaccion

parent: 03

← sub-workflow

span 07

Supervisor de calidad

parent: 06

span 08

Escritura en CRM

parent: 07

span 09

Persistencia de memoria

parent: 07

Una sola consulta por traceId reconstruye toda la cadena de pensamiento, atravesando los tres workflows involucrados.

El valor práctico aparece el día del incidente. Cuando un cliente reclama que recibió una respuesta incorrecta, la pregunta operativa es: *¿qué contexto tenía el agente, qué herramienta consultó, qué le devolvió, y con qué versión de instrucciones redactó?* Con el `traceId` eso es una consulta. Sin él, es una tarde revisando ejecuciones sueltas en tres flujos distintos.

2.4 · Política de retención

Tipo de registro	Retención	Fundamento
Log estructurado de ejecución	12 meses	Auditoría retroactiva y análisis de tendencia interanual.
Métricas agregadas del panel	Indefinida	Peso despreciable, valor histórico alto.
Resumen consolidado de memoria	6 meses de inactividad	Vencido ese plazo se purga: es dato personal sin propósito activo.
Archivos de audio de clientes	Cero	Se procesan en memoria volátil de la ejecución y se destruyen al cerrar el flujo. Nunca se persisten.

Dimensión 3 · Gobernanza ética, ciberseguridad y compliance

3.1 · Control de sesgos y objetividad institucional

Los mecanismos aplicados en las instrucciones de sistema de cada agente:

- **Prohibición de inferencia sobre el interlocutor.** El agente responde a lo que el cliente pregunta y no modula el trato según lo que infiera de su nombre, su forma de escribir o su dirección de correo. No hay segmentación implícita de la calidad de atención.
- **Taxonomía cerrada de clasificación.** El coordinador elige entre categorías predefinidas y tiene prohibido inventar nuevas. Una taxonomía abierta permitiría que el modelo cree categorías con criterios no auditables.
- **Fundamentación obligatoria en fuentes.** El redactor solo puede afirmar lo que aparece en los datos recuperados. Ante ausencia de dato, la instrucción es declarar la ausencia, no completar con lo probable.
- **Evaluación contra evidencia, no contra plausibilidad.** La rúbrica del supervisor puntúa exactitud factual verificable contra las fuentes provistas. Un texto bien escrito pero infundado obtiene puntaje bajo.

3.2 · Mapa de riesgos de ciberseguridad

Riesgo	Impacto	Barrera implementada en el lienzo
Alucinación de datos operativos	Alto	El especialista de datos es determinista, no un modelo. El redactor solo puede afirmar lo que ese especialista devolvió. El supervisor verifica cada afirmación contra la fuente antes de habilitar la salida.
Inyección indirecta de prompt	Alto	El contexto histórico recuperado de la memoria se inyecta entre delimitadores rígidos, precedido de una instrucción explícita de tratarlo como datos y nunca como órdenes. Es una defensa real y necesaria: ese contexto contiene texto que en algún momento escribió un cliente, y sin la contención un mensaje malicioso persistido en el resumen se convertiría en instrucción en la sesión siguiente.
Envío no autorizado al cliente	Crítico	El conector de correo no tiene permiso de envío: solo puede crear borradores. La barrera es de permisos, no de instrucciones. Un prompt puede ser eludido; un permiso denegado, no.
Bucle infinito de auto-respuestas	Medio	Filtro determinista inmediatamente posterior al trigger de correo, que descarta auto-respuestas, avisos de ausencia, rebotes y remitentes no-reply antes de que entren al sistema.
Contaminación cruzada entre clientes	Alto	Toda lectura y escritura de memoria filtra por identificador de sesión. Ninguna consulta puede recuperar el contexto de otra conversación.
Fuga de datos por payload excesivo	Medio	Nodos de limpieza antes de cada sistema externo, que construyen el payload desde cero con el mínimo producto viable. Al canal del equipo llegan cinco campos, no el objeto completo de la conversación.
Exposición de credenciales	Crítico	Las claves viven en el almacén de credenciales de la plataforma, nunca en nodos ni en expresiones. Las exportaciones de flujo contienen el identificador de la credencial, jamás su valor. Permisos de mínimo privilegio en los cinco conectores.
Bucle de auto-corrección sin salida	Medio	El ciclo supervisor-redactor admite un solo reintento. Al segundo veredicto negativo el caso se congela y escala a una persona.

3.3 · Gobernanza de datos y privacidad

Validación de retención cero con los proveedores

Antes de que el sistema procese datos reales de clientes, la organización debe confirmar por escrito con cada proveedor de modelos que la información enviada por API **no se utiliza para entrenar modelos** y que rige una política de retención cero o acotada. Los principales proveedores ofrecen esta condición en sus términos de API —a diferencia de sus productos de consumo— y en planes empresariales admiten acuerdos formales de tratamiento de datos. La verificación es una tarea de las áreas legal y de sistemas, no del equipo técnico que implementa, y debe quedar documentada.

Advertencia sobre el estado actual del sistema. Durante el desarrollo se utilizaron modelos de capa gratuita a través de un enrutador de terceros. Ese esquema es adecuado para un entorno de pruebas con datos ficticios, pero **no es apto para datos reales de clientes**: las capas gratuitas suelen financiarse precisamente con el uso de los datos para mejora de modelos. La migración a credenciales con retención cero verificada es un prerequisite de la puesta en producción, no una mejora posterior.

Minimización en el diseño

- La memoria persiste un resumen analítico, no la conversación. Menos dato almacenado es menos superficie de exposición.
- Los audios de clientes se procesan en memoria volátil y se destruyen al cerrar la ejecución. No se guardan en ningún punto del sistema.
- Al CRM se escribe únicamente el objeto contacto. El sistema no vuelca la conversación completa en el registro comercial.
- Los logs registran identificadores y tamaños, no contenidos. Una auditoría puede reconstruir qué pasó sin leer lo que el cliente escribió.

3.4 · Modelo de responsabilidades

Rol	Responsabilidad	Cadencia
Responsable técnico	Salud de las ejecuciones, errores, latencia, rotación de credenciales	Revisión diaria del panel
Responsable de operación	Calidad de las respuestas, tasa de edición, ajuste de prompts	Revisión semanal
Responsable comercial	KPIs de negocio, ROI real contra el proyectado	Revisión mensual
Legal y sistemas	Cláusulas de retención de datos, permisos de conectores, política de purga	Revisión trimestral

3.5 · Criterios de suspensión

Condiciones que detienen el sistema sin requerir aprobación previa de nadie. Definirlas antes de que ocurran es lo que evita la discusión sobre quién tiene autoridad para apagarlo en el peor momento:

- La exactitud factual media cae por debajo de 3,5 sobre 5 durante dos días consecutivos.
- Se detecta una respuesta enviada que compromete dinero o condiciones comerciales fuera de alcance.
- El consumo diario supera tres veces la media móvil de la semana anterior.
- Un proveedor modifica sus condiciones de retención de datos.

En cualquiera de los cuatro casos el sistema vuelve a modo sombra —sigue procesando y produciendo borradores, pero ninguno se habilita para envío— hasta que se identifique la causa raíz.

Fuentes de las tarifas citadas (consultadas el 9 de septiembre de 2026): precios de API de OpenAI en developers.openai.com/api/docs/pricing; precios de API de Anthropic y descuento de lecturas de caché en benchlm.ai/anthropic/api-pricing. Las tarifas de modelos cambian con frecuencia: verificar antes de comprometer un presupuesto.